

# Práctica 1: Distribución Binomial con un Dado

## Objetivos

1. Medir la distribución del número de éxitos en bloques de  $n$  lanzamientos.
2. Calcular media y varianza y comparar con los valores teóricos.
3. Verificar el ajuste con una prueba de Chi-cuadrado de bondad de ajuste.

## Definición del Experimento

Se analiza el número de veces que se obtiene un "6" (éxito) al lanzar un dado 20 veces. Este es un experimento que sigue una distribución binomial.

$$X \sim \text{Bin}(n, p)$$

Donde:

- $n=20$  (número de lanzamientos en cada experimento)
- $p=1/6$  (probabilidad de obtener un 6 en un solo lanzamiento)

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import binom, chi2

# Cargar los datos
df = pd.read_csv('datos_practical.csv')

# Renombrar columnas para facilitar el acceso
df.columns = ['experimento', 'lanzamientos', 'exitos']
```

```
# Mostrar los primeros 5 experimentos
```

```
df
```

	experimento	lanzamientos	exitos
0	1	20	3
1	2	20	4
2	3	20	2
3	4	20	5
4	5	20	3
5	6	20	1
6	7	20	6
7	8	20	4
8	9	20	3
9	10	20	2
10	11	20	3
11	12	20	4

12	13	20	5
13	14	20	1
14	15	20	3
15	16	20	2
16	17	20	4
17	18	20	3
18	19	20	5
19	20	20	2
20	21	20	3
21	22	20	4
22	23	20	6
23	24	20	3
24	25	20	2

## Media y Varianza Teórica

La media (o valor esperado) y la varianza de una distribución binomial se calculan con las siguientes fórmulas:

**Media teórica:**  $\mu = np$

**Varianza teórica:**  $\sigma^2 = np(1 - p)$

```
# Parámetros de la distribución
n = 20
p = 1/6

# Cálculos teóricos
media_teorica = n * p
varianza_teorica = n * p * (1 - p)

print(f"Media teórica (μ): {media_teorica:.4f}")
print(f"Varianza teórica (σ²): {varianza_teorica:.4f}")

Media teórica (μ): 3.3333
Varianza teórica (σ²): 2.7778
```

## Estadísticos Muestrales

A partir de los datos recolectados, podemos calcular los estimadores de la media y la varianza.

**Media muestral:**  $\hat{k} = \frac{1}{N} \sum_{i=1}^N k_i$

**Varianza muestral (insesgada):**  $s^2 = \frac{1}{N-1} \sum_{i=1}^N (k_i - \hat{k})^2$

Donde:

- $N$  es el número total de experimentos.
- $k_i$  es el número de éxitos en el experimento  $i$ .

```
# Extraer la columna de 'exitos'
k_values = df['exitos']

# Calcular estadísticos muestrales
media_muestral = np.mean(k_values)
varianza_muestral = np.var(k_values, ddof=1) # ddof=1 para varianza insesgada

print(f"Media muestral ( $\bar{k}$ ): {media_muestral:.4f}")
print(f"Varianza muestral ( $s^2$ ): {varianza_muestral:.4f}")

Media muestral ( $\bar{k}$ ): 3.3200
Varianza muestral ( $s^2$ ): 1.8933
```

## Comparación de Frecuencias Observadas y Esperadas

Para evaluar visualmente qué tan bien se ajustan nuestros datos a una distribución binomial, podemos graficar la frecuencia observada de cada número de éxitos y compararla con la distribución de probabilidad teórica.

La probabilidad de obtener exactamente  $k$  éxitos en  $n$  lanzamientos está dada por la **función de masa de probabilidad (PMF)** de la distribución binomial:

$$P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}$$

```
# Frecuencias observadas
frecuencias_observadas = k_values.value_counts().sort_index()

# Rango de posibles éxitos
k_range = np.arange(0, n + 1)

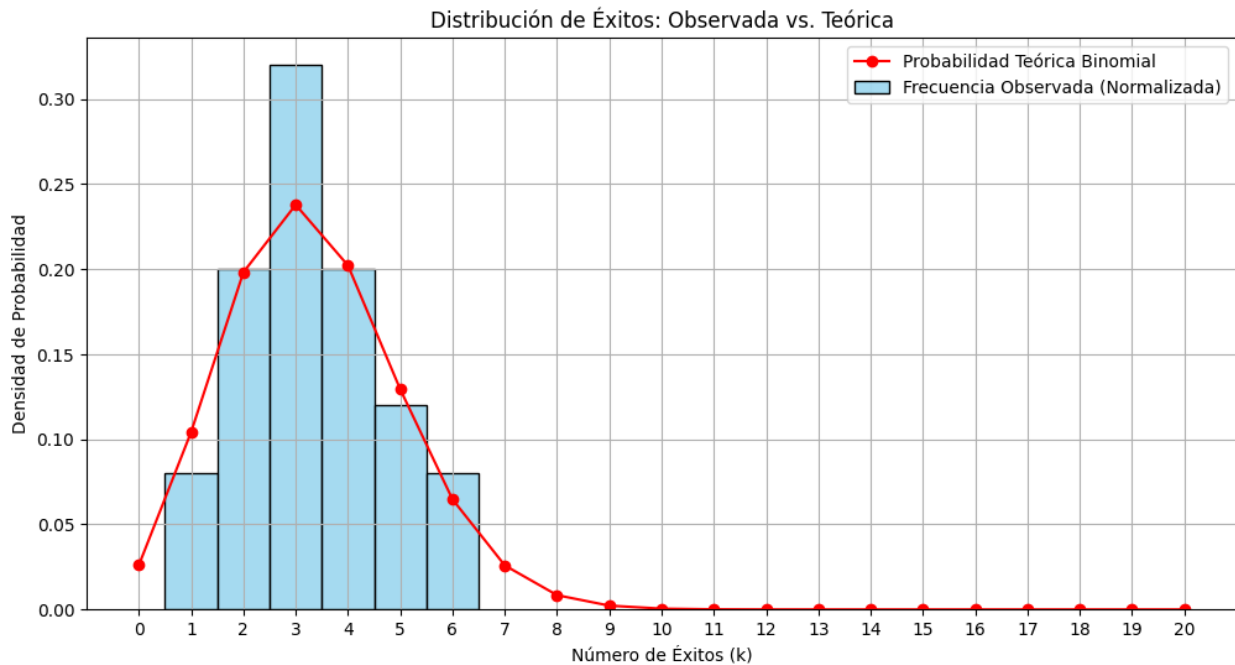
# Probabilidades teóricas
probabilidades_teoricas = binom.pmf(k_range, n, p)

# Gráfico de la distribución de frecuencias observadas
plt.figure(figsize=(12, 6))
sns.histplot(k_values, bins=np.arange(k_values.min(), k_values.max() + 2) - 0.5, stat='density', discrete=True, label='Frecuencia Observada (Normalizada)', color='skyblue')

# Gráfico de la distribución de probabilidad teórica
plt.plot(k_range, probabilidades_teoricas, 'ro-', label='Probabilidad Teórica Binomial')

plt.title('Distribución de Éxitos: Observada vs. Teórica')
plt.xlabel('Número de Éxitos (k)')
```

```
plt.ylabel('Densidad de Probabilidad')
plt.xticks(k_range)
plt.legend()
plt.grid(True)
plt.show()
```



## Prueba de Bondad de Ajuste Chi-cuadrado ( $\chi^2$ )

Para verificar formalmente si los datos observados se ajustan a la distribución binomial, utilizamos la prueba de Chi-cuadrado.

El estadístico de prueba se calcula como: 
$$\chi^2 = \sum_{i=1}^m \frac{(O_i - E_i)^2}{E_i}$$

Donde:

- $O_i$  es la frecuencia observada para la categoría  $i$ .
- $E_i$  es la frecuencia esperada para la categoría  $i$ , calculada como  $N \times P(X = k_i)$ .
- $m$  es el número de categorías.

**Hipótesis:**

- $H_0$ : Los datos siguen una distribución binomial con  $n=20$  y  $p=1/6$ .
- $H_1$ : Los datos no siguen dicha distribución.

Se comparará el valor de  $\chi^2$  calculado con un valor crítico de la distribución Chi-cuadrado con  $m - 1$  grados de libertad y un nivel de significancia  $\alpha$  (comúnmente 0.05). Si  $\chi^2_{calculado} > \chi^2_{critico}$  se rechaza  $H_0$ .

```
# Número total de experimentos
N = len(df)

# Crear tabla de frecuencias
frec_observada = k_values.value_counts().sort_index()
df_frec = pd.DataFrame({'observada': frec_observada})

# Calcular frecuencias esperadas
df_frec['prob_teorica'] = binom.pmf(df_frec.index, n, p)
df_frec['esperada'] = df_frec['prob_teorica'] * N

# Agrupar categorías con frecuencia esperada < 5
# Esta es una práctica común para la prueba de Chi-cuadrado
umbral = 5
if (df_frec['esperada'] < umbral).any():
    # Agrupar las categorías de cola
    cola = df_frec[df_frec['esperada'] < umbral]
    if not cola.empty:
        cola_observada = cola['observada'].sum()
        cola_esperada = cola['esperada'].sum()

        # Eliminar filas de la cola
        df_frec = df_frec[df_frec['esperada'] >= umbral]

        # Añadir la categoría agrupada
        df_frec.loc['>= ' + str(cola.index.min())] = [cola_observada,
np.nan, cola_esperada]

# Extraer frecuencias finales para la prueba
O = df_frec['observada'].values
E = df_frec['esperada'].values

# Calcular el estadístico Chi-cuadrado
chi2_calculado = np.sum((O - E)**2 / E)

# Grados de libertad
# m (número de categorías) - 1
grados_libertad = len(O) - 1

# Nivel de significancia
alpha = 0.05

# Valor crítico de Chi-cuadrado
chi2_critico = chi2.ppf(1 - alpha, grados_libertad)

# p-valor
```

```

p_valor = 1 - chi2.cdf(chi2_calculado, grados_libertad)

print("Tabla de Frecuencias para Prueba Chi-cuadrado:")
print(df_freq)
print("\n--- Resultados de la Prueba Chi-cuadrado ---")
print(f"Estadístico Chi-cuadrado calculado ( $\chi^2$ ): {chi2_calculado:.4f}")
print(f"Grados de libertad: {grados_libertad}")
print(f"Valor crítico de Chi-cuadrado ( $\alpha=0.05$ ): {chi2_critico:.4f}")
print(f"p-valor: {p_valor:.4f}")

```

*# Conclusión*

```

if chi2_calculado > chi2_critico:
    print("\nConclusión: Se rechaza la hipótesis nula ( $H_0$ ).")
    print("Los datos no parecen seguir una distribución binomial con n=20 y p=1/6.")
else:
    print("\nConclusión: No se puede rechazar la hipótesis nula ( $H_0$ ).")
    print("Los datos son consistentes con una distribución binomial con n=20 y p=1/6.")

```

Tabla de Frecuencias para Prueba Chi-cuadrado:

	observada	prob_teorica	esperada
exitos			
3	8.0	0.237887	5.947164
4	5.0	0.202204	5.055090
>= 1	12.0	NaN	12.417261

```

--- Resultados de la Prueba Chi-cuadrado ---
Estadístico Chi-cuadrado calculado ( $\chi^2$ ): 0.7232
Grados de libertad: 2
Valor crítico de Chi-cuadrado ( $\alpha=0.05$ ): 5.9915
p-valor: 0.6966

```

Conclusión: No se puede rechazar la hipótesis nula ( $H_0$ ).  
 Los datos son consistentes con una distribución binomial con n=20 y p=1/6.